

Makine Öğrenmesi ML

Temel Kavramlar
ve Süreçler — Adım Adım

GİRİŞ REHBERİ



Makine öğrenmesi nedir?



Veri toplama ve hazırlama



Keşifsel veri analizi (EDA)



Model seçimi ve eğitimi



Değerlendirme ve metrikler



Model iyileştirme ve dağıtım

Dr. Öğr. Üyesi Sevdanur GENÇ

İÇERİK

Bugün Ne Öğreneceğiz?

01

ML Nedir?

Tanım · Tarihçe · Neden önemli ·
Kullanım alanları

02

Veri Hazırlama

Toplama · Temizleme · Dönüştürme ·
Bölme

03

ML Türleri

Gözetimli · Gözetimsiz · Pekiştirmeli
öğrenme

04

Model Eğitimi

Algoritma seçimi · Hiperparametreler ·
Fit etme

05

Değerlendirme

Accuracy · Precision · Recall · F1 · ROC-
AUC

06

Dağıtım

Overfitting · Regularizasyon · Pipeline ·
Deploy

Makine Öğrenmesi Nedir?

Tanım

Makine öğrenmesi; bilgisayarların açıkça programlanmadan veriden öğrenmesini sağlayan yapay zeka dalıdır. Model, örneklerle bakarak kalıpları tanır ve yeni veriler üzerinde tahmin yapar.

Klasik Prog. vs ML

	Klasik	ML
Giriş	Veri + Kural	Veri + Çıktı
Çıkış	Sonuç	Kural (Model)
Kural	İnsan yazar	Makine öğrenir

Günlük Hayatta Kullanım Alanları

 Spam Filtresi

 Netflix Öneri

 Kredi Skoru

 Hastalık Tespiti

 Otonom Araç

 Ses Tanıma

Makine Öğrenmesi Türleri



Gözetimli Öğrenme

Etiketlenmiş verilerle eğitilir. Model, girdi-çıkı çiftlerinden kalıpları öğrenir.



Sınıflandırma · Regresyon

Algoritmalar:

Lineer Reg. · Karar Ağacı · SVM · Rastgele Orman · Sinir Ağları



Gözetimsiz Öğrenme

Etiketsiz verilerden gizli yapıları keşfeder. İnsan müdahalesi gerekmez.



Kümeleme · Boyut İndirgeme

Algoritmalar:

K-Means · DBSCAN · PCA · Otoenkoder



Pekiştirmeli Öğrenme

Ajan, çevresiyle etkileşerek ödül/ceza sinyalleriyle öğrenir.




Oyun oynama · Robotik

Algoritmalar:

Q-Learning · PPO · A3C · AlphaGo

Makine Öğrenmesi Pipeline'ı



⚠ Bu süreç doğrusal değil, döngüseldir!

Model iyi sonuç vermezse önceki adımlara dönülür: daha fazla veri toplanır, özellikler değiştirilir, farklı algoritma denenir. Gerçek dünya projelerinin çoğu zamanı veri hazırlamaya harcar — bu adım toplam sürenin %60–80'ini oluşturabilir.

Veri Toplama ve Ön İşleme



Veri Toplama

- Veritabanları (SQL, NoSQL)
- CSV / Excel dosyaları
- API'lar (REST, GraphQL)
- Web scraping
- Sensör & IoT verileri



Veri Temizleme

- Eksik değer doldurma (mean, median, mode)
- Aykırı değer tespiti (IQR, Z-score)
- Yinelenen satır silme
- Hatalı veri düzeltme
- Tutarsız format dönüştürme



Özellik Mühendisliği

- Normalizasyon (0-1 arası)
- Standardizasyon (z-score)
- Kategorik → Sayısal (Label/One-Hot)
- Yeni özellik türetme
- Boyut indirgeme (PCA)

Veri Bölme ve Keşifsel Analiz (EDA)



Veri Bölme Stratejisi

Eğitim (Train) 70%	Doğrulama (Val) 15%	Test 15%
-----------------------	---------------------------	-------------

- Eğitim seti → Model bu veriyle öğrenir
- Doğrulama seti → Hiperparametre ayarlamak için
- Test seti → Sadece son değerlendirmede kullanılır!
- ⚠ Test setine kesinlikle eğitim sırasında bakılmaz
- ⚠ Cross-validation: veriyi k parçaya bölerek tekrarlı test



EDA Nedir?

- Veri dağılımını anlamak
- Korelasyon analizi
- Histogram & box plot
- Eksik veri haritası
- Sınıf dengesizliği tespiti
- Özellik ilişkileri (pairplot)
- Özet istatistikler (mean, std)

Temel Makine Öğrenmesi Algoritmaları

Lineer Regresyon

Regresyon

Sürekli değer tahmini. $y = mx + b$ ilişkisini öğrenir.

📌 Ev fiyatı, sıcaklık tahmini

Lojistik Regresyon

Sınıflandırma

İkili sınıflandırma. Sigmoid ile olasılık üretir.

📌 Spam tespiti, hastalık riski

Karar Ağacı

Her ikisi

If-else ağaç yapısı. Yorumlaması kolay, güçlü.

📌 Müşteri segmentasyonu

Random Forest

Her ikisi

Çok sayıda karar ağacının ensemble'ı. Sağlam.

📌 Genel amaçlı, güçlü baseline

SVM

Sınıflandırma

En iyi ayırıcı düzlemi bulur. Yüksek boyutlarda iyi.

📌 Görüntü, metin sınıflama

K-Means

Kümeleme

K merkez etrafında verileri gruplar. Etiketsiz.

📌 Müşteri grupları, segmentasyon

Modeli Eğitmek: Temel Kavramlar

Eğitim Süreci Nasıl Çalışır?

Loss Fonksiyonu

Modelin ne kadar yanlış olduğunu ölçer. Eğitim amacı bunu minimize etmektir.

Gradyan İnişi

Loss'u azaltmak için parametreleri adım adım günceller.

Öğrenme Hızı (lr)

Her adımın büyüklüğünü belirler. Çok büyük → ıraksama, çok küçük → yavaş.

Epoch

Tüm eğitim verisinin bir kez işlenmesi. Genellikle çok sayıda epoch gerekir.

Batch Size

Her adımda kullanılan örnek sayısı. Mini-batch hem hız hem stabilite sağlar.

Hiperparametreler

n_estimators

Ağaç sayısı (RF)

max_depth

Ağaç derinliği

C / gamma

SVM düzenleyici

learning_rate

Adım büyüklüğü

k

K-Nearest Neighbors

 Grid Search veya Random Search ile en iyi değer bulunur.

Overfitting, Underfitting ve Doğru Denge



Underfitting

Train Hatası

Düşük

Test Hatası

Düşük

Model çok basit, eğitim verisini bile öğrenemedi. Bias yüksek.

Çözüm Yolları

- ✓ Daha karmaşık model seç
- ✓ Daha fazla özellik ekle
- ✓ Regularizasyonu azalt



Doğru Fit ✓

Train Hatası

Yüksek

Test Hatası

Yüksek

Model genel kalıpları öğrendi. Hem eğitim hem testte başarılı.

Çözüm Yolları

- ✓ Cross-validation kullan
- ✓ Uygun model karmaşıklığı
- ✓ Yeterli veri



Overfitting

Train Hatası

Çok Yüksek

Test Hatası

Düşük

Model eğitim verisini ezberledi, yeni veriye genelleyemiyor. Variance yüksek.

Çözüm Yolları

- ✓ Daha fazla veri toplama
- ✓ Regularizasyon (L1/L2)
- ✓ Dropout · Erken durdurma

Model Değerlendirme Metrikleri



Sınıflandırma Metrikleri

Karışıklık Matrisi:

TP Doğru Pozitif	FP Yanlış Pozitif
FN Yanlış Negatif	TN Doğru Negatif

Accuracy

Genel doğruluk oranı

$$(TP+TN) / \text{Toplam}$$

Precision

Pozitiflerin ne kadarı gerçek?

$$TP / (TP+FP)$$

Recall

Gerçek pozitifleri ne kadar yakaladık?

$$TP / (TP+FN)$$

F1 Score

Precision ve Recall'un harmonik ortalaması

$$2 \times (P \times R) / (P + R)$$



Regresyon Metrikleri

MAE

Mean Absolute Error

Hataların mutlak ortalaması. Yorumlaması kolay.

MSE

Mean Squared Error

Hataların karelerinin ortalaması. Büyük hataları cezalandırır.

RMSE

Root MSE

MSE'nin karekökü. Orijinal birimde hata.

R²

R-Squared

Modelin varyansı ne kadar açıkladığı. 1 = mükemmel.

Python Ekosistemi: ML Araçları ve Kütüphaneleri

NumPy

Sayısal Hesaplama

Çok boyutlu diziler ve matematiksel işlemler. ML'in temeli.

```
import numpy as np
np.array([1, 2, 3])
```

Pandas

Veri Manipülasyonu

DataFrame yapısı ile veri okuma, temizleme, dönüştürme.

```
import pandas as pd
df = pd.read_csv('data.csv')
```

Matplotlib / Seaborn

Görselleştirme

Grafik çizme, veri keşfi (EDA) ve sonuç sunumu.

```
import seaborn as sns
sns.heatmap(corr)
```

scikit-learn

ML Framework

Neredeyse tüm klasik ML algoritmaları. Pipeline, Grid Search.

```
from sklearn.ensemble
import RandomForestClassifier
```

TensorFlow / Keras

Derin Öğrenme

Sinir ağı tasarımı ve eğitimi. Google tarafından geliştirildi.

```
model.add(Dense(64,
activation='relu'))
```

PyTorch

Derin Öğrenme

Araştırma odaklı, dinamik graflar. Meta tarafından geliştirildi.

```
import torch
tensor = torch.tensor([1.])
```

Uçtan Uca Örnek: Müşteri Kaybı Tahmini (Churn)



Teşekkürler!

Ana Çıkarımlar:

- 🤖 ML = Veriden öğrenen sistemler
- 🔄 Süreç döngüseldir: deney → ölçüm → iyileştirme
- 📊 Veri hazırlama en kritik adımdır (%60-80 zaman)
- ⚖️ Overfitting/Underfitting dengesini koru
- 📈 Metriği probleme göre seç (F1 vs Accuracy)
- 🚀 Başlamak için sklearn + Pandas yeterli!

BAŞLANGIÇ REHBERİ

Makine Öğrenmesi

Başlamak İçin:

- 📁 scikit-learn.org — Belgeler
- 📖 [Kaggle.com](https://kaggle.com) — Veri setleri & kurslar
- 🎓 fast.ai — Ücretsiz derin öğrenme
- 📄 [Google Colab](https://colab.research.google.com) — Ücretsiz GPU

"Veri, yeni petrol değil;
veriyi işleyen model, yeni değerdir."