

ML

VS

QML

Kuantum Makine Öğrenmesi

Adım Adım Karşılaştırma

Workshop

✿ Klasik hesaplama → Kuantum hesaplama

🧠 Sinir ağları → Kuantum devreler

📊 Özellik uzayı → Hilbert uzayı

🔬 sklearn → PennyLane

⚡ Algoritma karşılaştırmaları

🚀 NISQ dönemi ve gelecek

Dr. Öğr. Üyesi Sevdanur GENÇ – Balıkesir Üniversitesi Bilgisayar Mühendisliği

Bugün Ne Öğreneceğiz?

01

Temeller

Bit vs Kubit · Klasik vs Kuantum hesaplama · Neden QML?

02

Veri & Kodlama

Feature engineering vs Quantum encoding · Amplitude, Angle, Basis

03

Modeller

Sinir ağı → QNN · SVM → QSVM · Karar ağacı → QAOA

04

Eğitim

Backprop vs Parameter-Shift · Loss fonksiyonları · Optimizerlar

05

Kod & Araçlar

sklearn → PennyLane · Qiskit · Gerçek donanım

06

Performans & Gelecek

Karmaşıklık · NISQ · Barren Plateau · Ne zaman QML?

Bit vs Kubit: Bilginin Temel Birimi

⚡ KLASİK BİT

0 veya 1

İki kesin durum, arası yok

Durum sayısı 2 (0 veya 1)

Ölçüm etkisi Durumu değiştirmez

Paralellik Seri işlem

Gürültü Hata düzeltmeli

Donanım Transistör

VS

⚙ KUBİT (Quantum Bit)

$\alpha|0\rangle + \beta|1\rangle$

$|\alpha|^2 + |\beta|^2 = 1$ (Normalizasyon koşulu)

Durum sayısı Sonsuz (süperpozisyon)

Ölçüm etkisi Durumu çökerter (collapse)

Paralellik Kuantum paralelizm


Gürültü Dekoherans sorunu

Donanım Süperiletken, foton, ion

Süperpozisyon: Kuantumun En Güçlü Özelliği

⚡ Klasik Bit


Para masada duruyorsa:
YA Tura (0) YA Yazı (1)



VS

⚙️ Kubit (Bloch Küresi)

Para havada dönerken:
HEM Tura HEM Yazı (süperpozisyon)



Dolanıklık — Klasik Korelasyonun Ötesi

Klasik: Bağımsız Değişkenler

İki zar attığınızda:
Birinin sonucu diğerini ETKİLEMEZ

Zar 1: 🎲 1-6 arası

Zar 2: 🎲 1-6 arası

Toplam: 36 farklı sonuç

Korelasyon: 0 (bağımsız)

VS

Kuantum: Dolanıklık (Entanglement)

Bell Durumu:
Birini ölçünce diğeri ANINDA belirlenir

$$|\Phi^+\rangle = (|00\rangle + |11\rangle) / \sqrt{2}$$


q_0 ölçüldü = 0 $\rightarrow$ q_1 kesinlikle 0

q_0 ölçüldü = 1 $\rightarrow$ q_1 kesinlikle 1

Mesafeden bağımsız (Einstein: 'gizemli uzaktan etki')

Neden Kuantum? 2^n 'in Gücü

Kubit Sayısı → Durum Uzayı ($\log_{10}$ ölçek)



1 kubit

2 durum

1 klasik bit gibi

10 kubit

1.024 durum

1 KB bellek = 1 chip

30 kubit

1 Milyar durum

= 4 GB RAM simülasyon

50 kubit

10^{15} durum


En güçlü klasik bilgisayar
sınırı

300 kubit

10^{90} durum

Evrendeki atom sayısından
fazla!

Klasik ML Pipeline — Ham Veriden Tahmine



Kullanılan Araçlar:

NumPy / Pandas


Scikit-learn

PyTorch / TensorFlow

Matplotlib / Seaborn

MLflow / WandB

QML Pipeline — Klasik Veriden Kuantum Tahmine



⚙️ Kuantum Bölgesi

Kullanılan Araçlar:

PennyLane

Qiskit (IBM)

Cirq (Google)

Amazon Braket

TensorFlow Quantum

Veri Temsili: Feature Vectors vs Quantum States

Klasik ML — Özellik Vektörü

$$\mathbf{x} = [x_1, x_2, \dots, x_n] \in \mathbb{R}^n$$

Veri noktası = n boyutlu Öklid uzayında bir nokta

Temsil Gerçek sayı vektörü

Boyut n (özellik sayısı)

Depolama $n \times 32$ bit float

Dönüşüm PCA, LDA, t-SNE

Örnek $[0.23, 1.45, -0.8, \dots]$

VS

QML — Kuantum Durumu

$$|\psi(\mathbf{x})\rangle = U(\mathbf{x})|0\rangle^n \in H^{2^n}$$

Veri = 2^n boyutlu Hilbert uzayında bir vektör

Temsil Karmaşık genlik vektörü

Boyut 2^n (üstel büyüme!)

Depolama Fiziksel kubitler

Dönüşüm Angle, Amplitude, Basis

Örnek $R_Y(x_1) \otimes R_Y(x_2) |0\rangle$

Quantum Encoding Yöntemleri — Veriyi Kubite Yüklemek

12
34

Basis Encoding

$$\mathbf{x}=(1,0,1) \rightarrow |101\rangle$$

Avantajlar:

- ✓ Çok basit
- ✓ Hızlı hazırlık

Dezavantajlar:

- ✗ Yalnızca ikili
- ✗ Sürekli değer yok

Kullanım: Arama algoritmaları



Angle Encoding

$$\mathbf{x}_i \rightarrow RY(\mathbf{x}_i)|0\rangle$$

Avantajlar:

- ✓ Kolay uygulama
- ✓ n özellik = n kubit

Dezavantajlar:

- ✗ Lineer ölçekleme
- ✗ Sınırlı ifade gücü

Kullanım: VQC, QNN (en yaygın)

Amplitude Encoding

$$|\psi\rangle = \sum \mathbf{x}_i / \|\mathbf{x}\| |i\rangle$$

Avantajlar:

- ✓ N veri $\rightarrow \log_2 N$ kubit
- ✓ Üstel sıkıştırma

Dezavantajlar:

- ✗ Hazırlık $O(N)$ kapı
- ✗ Normalizasyon şart

Kullanım: HHL, QML kernel

Sinir Ağı vs Variational Quantum Circuit (VQC)

Derin Sinir Ağı (DNN)




- Ağırlık: $W \in \mathbb{R}^{n \times m}$ (yüzer noktalı)
- Aktivasyon: ReLU, Sigmoid, Tanh
- Parametre: Milyonlar - Milyarlarca

- Eğitim: Backpropagation + SGD
- Donanım: CPU / GPU / TPU

VS

Variational Quantum Circuit (VQC)



- Parametre: $\theta \in [0, 2\pi]^P$ (rotasyon açıları)
- Aktivasyon: Kuantum kapıları (Rx, Ry, Rz, CNOT)
- Parametre: 10 - 1000 (NISQ döneminde)
- Eğitim: Parameter-Shift Rule / Backprop
- Donanım: Kuantum bilgisayar / Simülatör

SVM vs Quantum SVM — Kernel'ın Evrimi

Support Vector Machine (SVM)

$$K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$$

Özellik Uzayı $\phi: \mathbb{R}^n \rightarrow \mathbb{R}^d (d \gg n)$ **Kernel Trick**

İç çarpım hesabı ucuz

Popüler Kerneller

RBF, Polynomial, Linear

Karmaşıklık $O(N^2 - N^3)$ eğitim**En İyi Nokta**

Tabular, küçük veri

VS

Quantum SVM (QSVM)

$$K_q(x_i, x_j) = |\langle \psi(x_i) | \psi(x_j) \rangle|^2$$

Özellik Uzayı $\phi: \mathbb{R}^n \rightarrow \text{Hilbert } (2^n \text{ boyut})$ **Kernel Trick**

Kuantum devre ile ölçüm

Kernel Tipi

ZZ Feature Map, IQP

Karmaşıklık $O(\log N)$ (teorik)**En İyi Nokta**


Kuantum veri, kimya

Data Re-Uploading: Tek Kubitin Evrensel Gücü

💡 Pérez-Salinas et al. (2020)

Klasik ML'de daha fazla nöron = daha fazla güç.

QML'de tek kubit bile evrensel sınıflandırıcı olabilir — eğer veri tekrar tekrar yüklenirse!




Fourier Perspektifi:

Her re-upload katmanı öğrenebilir frekans kümesini genişletir:


$$f_{\theta}(x) = \sum_{\omega} c_{\omega} \cdot e^{i\omega x}$$

Katman → Doğruluk



Daha fazla katman = daha geniş Fourier spektrumu

Hibrit Kuantum-Klasik Mimari



Klasik Bileşenler

- Veri ön-işleme
- Loss fonksiyonu
- Optimizasyon

Kuantum Bileşenler

- Quantum encoding ($U(x)$)
- Variational ansatz ($U(\theta)$)
- Kuantum ölçüm ($\langle M \rangle$)

Gradyan Hesaplama: Backpropagation vs Parameter-Shift Rule

Backpropagation (Klasik ML)

$$\partial L / \partial w = \delta \cdot x^T$$

1 İleri geçiş: $\hat{y} = f(x; w)$ hesapla

2 Kayıp: $L = \text{loss}(\hat{y}, y)$

3 Geri geçiş: $\partial L / \partial w = \text{zincir kuralı}$

4 Güncelle: $w \leftarrow w - \eta \cdot \partial L / \partial w$

✓ Tek geçişte tüm gradyanlar

✓ $O(P)$ değil $O(1)$ devre

✓ GPU ile paralel

VS

Parameter-Shift Rule (QML)

$$\partial f / \partial \theta = [f(\theta + \pi/2) - f(\theta - \pi/2)] / 2$$

1 $\theta_i + \pi/2$ ile devre çalıştır

2 $\theta_i - \pi/2$ ile devre çalıştır

3 Gradyan = $(f_+ - f_-) / 2$

4 Her parametre için 2 çalıştırma

✓ Gerçek kuantum donanımında çalışır

✓ Sonlu farktan daha kesin

✗ P parametre $\rightarrow 2P$ devre çalışması

Optimizer Karşılaştırması: SGD, Adam vs Kuantum Optimizerlar

SGD Klasik

$$w \leftarrow w - \eta \cdot \nabla L$$

Basit gradyan iniş. Sabit öğrenme hızı sorunlu.

Kullanım:

Büyük veri, iyi tuning ile iyi sonuç

```
SGD(lr=0.01, momentum=0.9)
```

Adam Klasik

$$w \leftarrow w - \eta \cdot m / (\sqrt{v} + \epsilon)$$

Adaptif momentum + ikinci moment. QML simülatöründe çalışır.

Kullanım:

QML'de backprop ile standart seçim

```
AdamOptimizer(stepsize=0.05)
```

Adagrad Klasik/QML

$$w \leftarrow w - \eta / \sqrt{G} \cdot \nabla L$$

Birikimli gradyan. Hinge loss ile uyumlu.

Kullanım:

QML hinge loss + sparse gradyanlar

```
AdagradOptimizer(stepsize=0.08)
```

QNG Kuantum

$$\theta \leftarrow \theta - \eta \cdot F^{-1} \nabla L$$

Quantum Natural Gradient. Fubini-Study metriği kullanır.

Kullanım:

Derin VQC, barren plateau azaltma

```
QNGOptimizer(stepsize=0.01)
```


Loss Fonksiyonları: Klasik ML vs QML

Loss	Klasik ML	Quantum ML
MSE	Regresyon için $\frac{1}{2}\sum(\hat{y}-y)^2$	VQE, fonksiyon öğrenme $\langle \psi H \psi \rangle$ minimizasyonu
BCE	Binary sınıflandırma $-\sum[y \cdot \log(p) + (1-y) \cdot \log(1-p)]$	QNN sınıflandırma (dikkat: sigmoid doygunluğu!)
Hinge	SVM: $\max(0, 1-y \cdot f(x))$ Marjin maksimizasyonu	QSVM, sınıf çöküşüne dirençli
Fidelity	<i>Kullanılmaz</i>	QML özel: $ \langle \psi_{\text{hedef}} \psi_{\text{model}} \rangle ^2$
QAOA	<i>Kullanılmaz</i>	Kombinatoryal opt.: $\langle C \rangle = -\langle \psi(\gamma, \beta) C \psi(\gamma, \beta) \rangle$

QML Araç Ekosistemi — Hangi Framework Ne Zaman?

 PennyLane <i>by Xanadu</i>	 Qiskit <i>by IBM</i>	 Cirq <i>by Google</i>	 TF Quantum <i>by Google</i>
Kullanım: QML araştırması Hibrit kuantum-klasik modeller Güçlü Yanlar: PyTorch/TF entegrasyonu Automatic diff. Backend bağımsız	Kullanım: IBM Quantum donanımı Kuantum devre tasarımı Güçlü Yanlar: Gerçek donanım erişimi Geniş dokümantasyon Büyük topluluk	Kullanım: Google donanımı Düşük seviyeli kontrol Güçlü Yanlar: Sycamore entegrasyonu Detaylı hata modeli	Kullanım: TensorFlow ile entegre Kuantum-klasik hibrit Güçlü Yanlar: Keras benzeri API TPU + kuantum
Dil: Python	Dil: Python	Dil: Python	Dil: Python
Araştırma + Prodüksiyon	Eğitim + Prodüksiyon	İleri Araştırma	ML mühendisleri

Kod Karşılaştırması: sklearn vs PennyLane

Klasik ML

Klasik SVM — scikit-learn

```
from sklearn.svm import SVC
from sklearn.datasets import make_moons

X, y = make_moons(n_samples=200)

# Model oluştur & eğit
model = SVC(kernel='rbf', C=1.0)
model.fit(X_train, y_train)

# Tahmin & değerlendirme
y_pred = model.predict(X_test)
acc = accuracy_score(y_test, y_pred)
print(f'Doğruluk: {acc:.1%}')
```

Quantum ML

Quantum SVM — PennyLane

```
import pennylane as qml
import pennylane.numpy as pnp

dev = qml.device('default.qubit', wires=2)

@qml.qnode(dev, diff_method='backprop')
def circuit(params, x):
    qml.AngleEmbedding(x, wires=[0,1])
    qml.StronglyEntanglingLayers(
        params, wires=[0,1])
    return qml.expval(qml.PauliZ(0))

opt = qml.AdamOptimizer(stepsize=0.05)
```

Algoritma Karmaşıklığı: Klasik vs Kuantum

Problem	Klasik Algoritma	Klasik O(...)	Kuantum Algoritma	Kuantum O(...)	Hız Kazanımı
Doğrusal Sistem $Ax=b$	Gaussian Eliminasyon	$O(N^3)$	HHL Algoritması	$O(\log N \cdot \kappa^2)$	Üstel
Sırasız Arama	Doğrusal Arama	$O(N)$	Grover Arama	$O(\sqrt{N})$	Karesel
Çarpanlara Ayrma	En iyi klasik	$O(e^{\{N^{1/3}\}})$	Shor Algoritması	$O(N^3)$	Üstel
Öz Değer Bulma	QR Algoritması	$O(N^3)$	QPE	$O(\log N)$	Üstel
ML Kernel Matrisi	Doğrudan Hesap	$O(N^2 \cdot d)$	Quantum Kernel	$O(N^2 \cdot \log d)$	Polinom
Optimizasyon (Komb.)	Brute Force	$O(2^N)$	QAOA (p katman)	$O(p \cdot N)$	Üstel (pratik için)

Barren Plateau: QML'nin En Büyük Açık Problemi

⚠ Barren Plateau Nedir?

Derin VQC'lerde gradyanlar üstel olarak küçülür:


$$\text{Var}[\partial L / \partial \theta_k] \in O(1/2^n)$$

Pratik anlamı:

- Gradyan $\approx 0 \rightarrow$ Model öğrenmiyor
- Qubit sayısı arttıkça kötüleşiyor
- Random başlangıç parametreleri riskli
- Derin devreler öğrenemez

Çözüm Önerileri:

- ✓ Küçük başlangıç parametreleri $[-\pi/6, \pi/6]$
- ✓ Yerel ölçüm operatörleri
- ✓ Layerwise training
- ✓ Identity blocks başlangıcı



NISQ Dönemi — Bugün Neredeyiz?

NISQ = Noisy Intermediate-Scale Quantum

1 2
3 4

Kubit Sayısı

10 – 1000+

IBM: 1121 qubit (Condor, 2023)



Kapı Hata Oranı

%0.1 – 1

Mükemmel değil; hata var



Coherence Süresi

μs – ms

Çok kısa → sığ devreler



Bağlantısallık

Kısmi

Her kubit herkesle bağlı değil



Sıcaklık

~15 mK

Mutlak sıfıra yakın soğutma



Erişim

Bulut API

IBM, Google, AWS Braket

Kuantum Donanımı: Teknoloji Karşılaştırması

Teknoloji	Qubit Sayısı	Kapı Hatası	T ₂ (Ömür)	Sıcaklık	Ölçekleme	Sınır
Süperiletken (Transmon) IBM · Google	50-1000+	~0.1%	~100 µs	15 mK	✓ Ölçeklenebilir	Kısa ömür, soğutma
Hapsolmuş İon (Trapped Ion) IonQ · Quantinuum	10-50	~0.01%	~1 s	Oda sıcak.	X Ölçekleme zor	Yavaş kapı hızı
Foton (Photonic) Xanadu · PsiQ	Değişken	Kayıp-sınırlı	Oda sıcak.	Oda sıcak.	✓ Ağ üzerinden	Ölçüm verimsizliği
Topological Kubit Microsoft	Henüz az	Teorik: ~0	Uzun	mK	✓ Hata dirençli	Henüz olgun değil

Ne Zaman ML, Ne Zaman QML?

✓ Klasik ML Kullan

Görüntü / NLP / Ses Derin öğrenme kazanır

Büyük veri (milyon+) Klasik GPU yeterli

Gerçek zamanlı tahmin Düşük latency gerekli

Tabular veri XGBoost/RF çoğunlukla iyi

Prodüksiyon sistemi Olgun altyapı mevcut

Kısıtlı bütçe GPU bulut < Kuantum

VS

⚙ QML Kullan (veya Araştır)

Kimya simülasyonu Molekül/enerji hesabı

Kuantum veri Kuantum sensör çıktısı

Küçük, karmaşık veri Kernel avantajı olabilir

Optimizasyon Kombinatoryal problemler

Araştırma projesi Yeni frontier keşfetmek

Kuantum avantaj testi Klasikle benchmark

QML Uygulama Alanları — Nerede Gerçek Potansiyel Var?

İlaç & Kimya

Molekül enerji hesabı
Protein katlama optimizasyonu
Drug discovery hızlandırma

Yüksek Potansiyel

Finans

Portföy optimizasyonu
Risk analizi
Fiyatlandırma modelleri

Orta-Yüksek

Kriptografi

Post-kuantum şifreleme
Kuantum anahtar dağıtımı
Shor ile RSA kırma

Yüksek (Tehdit)

Robotik & Opt.

Rota optimizasyonu (TSP)
Üretim planlaması
Lojistik ağları

Orta Potansiyel

Malzeme Bilimi

Yeni malzeme keşfi
Süperiletken tasarım
Kvantum magnetizma


Yüksek Potansiyel

Biyoinformatik

DNA dizi hizalama
Protein yapı tahmini
Gene expression analizi

Araştırma Aşaması

Kuantum Hesaplama Yol Haritası 2020–2030+



ÖZET KARŞILAŞTIRMA

ML vs QML — Kapsamlı Karşılaştırma Tablosu

Özellik	Klasik ML	Quantum ML
Temel Birim	Bit (0 veya 1)	Kubit ($ 0\rangle + 1\rangle$ süperpoz.)
Veri Temsili	R^n vektör (float)	Hilbert uzayı (karmaşık)
Model	DNN, SVM, RF, GBM	VQC, QNN, QSVM, QAOA
Parametre Sayısı	Milyon - Milyar	10 - 1000 (NISQ sınırı)
Eğitim Yöntemi	Backpropagation	Parameter-Shift Rule
Optimizer	SGD, Adam, AdaGrad	Adam, QNG, Adagrad
Donanım	CPU / GPU / TPU	Kuantum bilgisayar
Framework	PyTorch, TF, sklearn	PennyLane, Qiskit, Cirq
Olgunluk	Çok olgun, prodüksiyon	NISQ: aktif araştırma
En İyi Kullanım	Görüntü, NLP, tabular	Kimya, optimizasyon, kuantum veri
Mevcut Sınır	Hesap gücü & veri	Gürültü, dekoherans, qubit sayısı

HANDS-ON

Bugünkü Alıştırmalar — Adım Adım Yaparak Öğren

01

Bloch Küresini Keşfet

H, X, Y, Z kapılarını uygula, Bloch küresi üzerindeki etkiyi gözlemle.

✂ PennyLane · Matplotlib

🕒 15 dk

02

Kuantum Kodlama

Klasik veriyi Angle, Amplitude ve Basis encoding ile kubite yükle. Karşılaştır.

✂ PennyLane AngleEmbedding

🕒 20 dk

03

İlk VQC Devreni Kur

StronglyEntanglingLayers ile 2 kubitli devre, parameter-shift ile eğit.

✂ PennyLane SEL · Adam

🕒 25 dk

04

QSVM vs SVM

make_circles verisi: Quantum kernel vs RBF kernel doğruluk karşılaştırması.

✂ PennyLane · sklearn

🕒 25 dk

05

Hibrit Sınıflandırıcı

Make Moons: AngleEmbedding + SEL + Hinge Loss + Mini-batch eğitim.

✂ PennyLane · backprop

🕒 30 dk

06

Data Re-Uploading

Tek kubit ile $\sin(x)$ öğren. Farklı katman sayısı dene, MSE karşılaştır.

✂ PennyLane · Adam

🕒 20 dk

KAYNAKLAR

Nereden Başlarsın? Kaynaklar & Yol Haritası


Temel Makaleler

- Biamonte et al. (2017) — Quantum Machine Learning · Nature
- Cerezo et al. (2021) — Variational Quantum Algorithms
- Pérez-Salinas (2020) — Data Re-Uploading · Quantum
- McClean et al. (2018) — Barren Plateaus in QNN
- Schuld & Killoran (2019) — QML in Feature Hilbert Spaces

Online Kaynaklar

- pennylane.ai/qml — PennyLane resmi eğitimler
- qiskit.org/learn — IBM Quantum Learning
- quantumai.google — Google Cirq tutorials
- Coursera: Quantum ML (University of Toronto)
- arXiv: quant-ph — Güncel araştırmalar

Önerilen Öğrenme Yolu



Teşekkürler!

Ana Çıkarımlar:

- Kuantum hesaplama yeni bir bilişim paradigması
- QML, ML'nin üzerine inşa edilir — onu değiştirmez
- ⚙️ Qubit = süperpozisyon + dolanıklık = güç
- 🔧 VQC = parametre + encoding + ölçüm
- ⚠️ NISQ dönemi: sınırları bil, beklentini ayarla
- 🚀 Potansiyel: kimya, optimizasyon, kuantum veri

Workshop

ML vs QML

Faydalı Bağlantılar:

- 📁 pennylane.ai
- 🔬 qiskit.org/learn
- 📄 arxiv.org/quant-ph
- 💻 [Google Colab Notebook](#)

"Kuantum hesaplama ve makine öğrenmesinin kesişimi, bilgisayar biliminin en heyecan verici sınırlarından biridir."